



İstanbul Üniversitesi – Cerrahpaşa

Mühendislik Fakültesi – Bilgisayar Mühendisliği

Uluslararası Futbol Maç Sonuçları Analizi

Veri Bilimi — Final Projesi

Yiğit Delen

1306230013

GitHub Repo Link: <https://github.com/yigitd3len/veri-bilimi-final-projesi>

1. Problem Tanımı ve Amaç

Bu proje, 1872'den 2024'e uzanan uluslararası A Milli Takım maçlarına ait geniş kapsamlı bir veri seti üzerinde uçtan uca bir veri bilimi iş akışı uygulamayı amaçlamaktadır. Çalışmanın temel motivasyonu, futbol kamuoyunda sıkça tartışılan üç popüler inanışı sistematik biçimde veriyle test etmektir: ev sahibi olmanın gerçek bir avantaj sağlayıp sağlamadığı, modern futbolun daha az gollü hâle gelip gelmediği ve oynanan zeminin maç sonucunu ne ölçüde etkilediği. Bu sorulara ek olarak, sınırlı sayıda öznitelik kullanılarak maç sonucunun ne derece tahmin edilebilir olduğu da bir sınıflandırma modeliyle incelenmiştir.

1.1 Araştırma Soruları

- Ev sahibi avantajı gerçek mi? Ev sahibi takımlar istatistiksel olarak deplasman takımlarından belirgin şekilde daha mı fazla kazanıyor?
- Futbol giderek daha az gollü bir hâl mi alıyor? Maç başına atılan gol sayısı 1930'dan günümüze nasıl bir seyir izlemiştir?
- Tarafsız sahada oynanan maçlar sonucu etkiliyor mu? Ev sahibi avantajı, maç tarafsız bir zeminde oynandığında ortadan kalkıyor mu?
- Maç sonucu (ev sahibi galibiyeti / beraberlik / deplasman galibiyeti) makine öğrenmesi ile makul bir doğrulukla tahmin edilebilir mi?

2. Kullanılan Veri Seti ve Kaynağı

Analizde kullanılan veri seti, 30 Kasım 1872'de oynanan ilk resmî uluslararası maçtan 2024 yılına kadar oynanmış A Milli Takım karşılaşmalarını içermektedir.

Veri Seti Adı	International Football Results (1872–2024)
Kaynak	Kaggle (martj42/international-football-results-from-1872-to-2017)
Lisans	CC0: Public Domain (Kamuya Açık)
Boyut	49.494 satır (maç), 9 sütun
Değişkenler	date, home_team, away_team, home_score, away_score, tournament, city, country, neutral

3. Yöntem

3.1 Veri Temizleme

Ham veri seti incelendiğinde home_score ve away_score sütunlarında toplam 13 eksik değer tespit edilmiştir; bu satırlar analiz için yeterli bilgi içermediğinden veri setinden çıkarılmıştır. Tarih sütunu datetime tipine dönüştürülerek yıl bilgisi ayrı bir sütun olarak türetilmiştir.

Aykırı değer kontrolünde 20 golün üzerindeki sonuçlar (9 maç) incelenmiş ve bunların büyük ölçekli elemeler veya tarihî nitelikteki istisnai sonuçlar olduğu görülerek veri setinden çıkarılmıştır. Temizleme adımları sonrasında analiz için 49.472 maçlık tutarlı bir veri seti elde edilmiştir.

3.2 Keşifsel Veri Analizi

Sonuç değişkeni, ev sahibi ve deplasman skorları karşılaştırılarak "Ev Sahibi Galip", "Beraberlik" ve "Deplasman Galip" şeklinde üç kategoride yeniden kodlanmıştır. Ev sahibi avantajına ilişkin analizlerde, tarafsız sahada oynanan maçların ev sahibi kavramını anlamsız kıldığı göz önünde bulundurularak yalnızca neutral=False olan maçlar (36.351 maç) kullanılmıştır.

3.3 Modelleme Yaklaşımı

Üçüncü araştırma sorusu için Random Forest sınıflandırma algoritması tercih edilmiştir. Bu yöntemin seçilme gerekçeleri şunlardır: hedef değişken üç kategoriden oluştuğu için bir sınıflandırma problemidir; Random Forest, çok sayıda karar ağacının oylamasına dayandığından tekil bir karar ağacına kıyasla aşırı öğrenmeye (overfitting) karşı daha dayanıklıdır; kategorik ve sayısal öznitelikleri bir arada işleyebilir ve özellik önem dereceleri yorumlanabilir bir çıktı sunar.

Modelde kullanılan öznitelikler tarafsız saha bilgisi (neutral), turnuva türü (LabelEncoder ile sayısallaştırılmış tournament) ve maçın oynandığı yıldır. Veri seti %80 eğitim (39.577 maç) ve %20 test (9.895 maç) olarak random_state=42 ile bölünmüş, 100 karar ağacından oluşan bir RandomForestClassifier eğitilmiştir. Kapsamlı bir hiperparametre optimizasyonu bu projenin kapsamı dışında tutulmuş, tek ve savunulabilir bir model ile sonuç üretilmesi hedeflenmiştir.


4. Bulgular

4.1 Araştırma Sorusu 1 — Ev Sahibi Avantajı

Tarafsız olmayan 36.351 maç incelendiğinde, ev sahibi takımların maçların %50,7'sini kazandığı, deplasman takımlarının ise yalnızca %26,4'ünü kazanabildiği görülmüştür. Beraberlik oranı %22,9 olarak gerçekleşmiştir. Ortalama gol sayısı açısından da ev sahibi takımlar maç başına 1,79 gol atarken deplasman takımları yalnızca 1,11 gol atabilmektedir.


%50,7 Ev Sahibi Galibiyeti	%22,9 Beraberlik	%26,4 Deplasman Galibiyeti
--------------------------------------	----------------------------	--------------------------------------

Uluslararası Maçlarda Sonuç Dağılımı (1872-2024)



Şekil 1. Uluslararası maçlarda sonuç dağılımı (tarafsız olmayan maçlar, n=36.351)

Ev Sahibi Avantajı Analizi




Şekil 2. Ev sahibi ve deplasman takımların ortalama gol sayısı ile kazanma oranlarının karşılaştırması

Bu bulgular, ev sahibi avantajının yalnızca anekdota dayalı bir izlenim olmadığını, hem kazanma oranı hem de gol verimliliği açısından tutarlı ve belirgin bir farkla istatistiksel olarak gözlemlenebilir bir fenomen olduğunu göstermektedir.

4.2 Araştırma Sorusu 2 — Gol Ortalamasının Zaman İçindeki Değişimi

1930 sonrası döneme odaklanan analizde, maç başına ortalama toplam gol sayısının dönemler arasında gerilediği gözlemlenmiştir: 1930–1970 arası dönemde ortalama 3,81 gol/maç görülürken, bu değer 1970–2000 ve 2000–2024 dönemlerinde 2,75 gol/maça gerilemiştir.




Şekil 3. 1930–2024 yılları arasında maç başına ortalama toplam gol trendi (5 yıllık hareketli ortalama ile)

Gerileme özellikle 1930–1970 ile sonraki dönemler arasında belirgindir; 1970 sonrasında ortalama görece istikrarlı bir seyir izlemektedir. Bu örüntü, savunma taktiklerinin profesyonelleşmesi, fiziksel hazırlık ve oyun disiplindeki gelişmelerle tutarlı bir yorum sunmaktadır; ancak veri setinde taktiksel değişkenler bulunmadığından bu açıklama sınırlamalar bölümünde belirtildiği gibi temkinli ele alınmalıdır.

4.3 Araştırma Sorusu 3 — Tarafsız Saha Etkisi

Veri setindeki 13.121 maç tarafsız sahada, 36.351 maç ise ev sahibi/deplasman düzeninde oynanmıştır. Normal maçlarda ev sahibi kazanma oranı %50,7 iken, tarafsız sahada oynanan maçlarda "ev sahibi" olarak listelenen takımın kazanma oranı %44,2'ye gerilemektedir; aradaki fark 6,6 puandır.



Şekil 4. Tarafsız saha ile taraflı saha arasında maç sonucu oranlarının karşılaştırması


Bu sonuç, ev sahibi avantajının önemli bir kısmının saha sahipliğinden değil; seyirci desteği, sahaya aşinalık ve seyahat yorgunluğunun olmaması gibi tarafsız sahada ortadan kalkan faktörlerden kaynaklandığını düşündürmektedir.

4.4 Araştırma Sorusu 4 — Makine Öğrenmesi ile Maç Sonucu Tahmini

Random Forest modeli, test setinde %46,9 doğruluk elde etmiştir. Üç sınıflı bir problemde rastgele tahminin beklenen doğruluğunun %33 olduğu düşünüldüğünde, model rastgele tahminin belirgin biçimde üzerinde bir performans sergilemektedir.

%46,9 Model Doğruluğu	%33,3 Rastgele Tahmin	+13,6 puan İyileşme
---------------------------------	---------------------------------	-------------------------------

Sınıf bazında performans incelendiğinde model, en yüksek başarıyı %85 recall ile "Ev Sahibi Galip" sınıfında göstermiştir; bu da veri setindeki en baskın ve en tutarlı örüntünün yine ev sahibi avantajı olduğunu doğrulamaktadır. Buna karşılık beraberlik sınıfında recall yalnızca %7 düzeyinde kalmıştır; bu durum, beraberliğin doğası gereği daha az öngörülebilir ve modelde kullanılan üç öz nitelikle ayırt edilmesi zor bir sonuç olmasından kaynaklanmaktadır.



Şekil 5. Karmaşıklık matrisi (solda) ve özellik önem dereceleri (sağda)

Özellik önem analizi, modelin tahminlerinde en belirleyici değişkenin yıl (%57,4) olduğunu, bunu turnuva türünün (%39,6) izlediğini, tarafsız saha bilgisinin ise görece olarak daha düşük bir katkı (%3,0) sağladığını göstermektedir. Yılın bu denli yüksek bir öneme sahip olması, modelin örtük biçimde dönemsel oyun stillerini ve turnuva yapılarındaki zamansal değişimleri öğrenmiş olabileceğine işaret etmektedir.

5. Sınırlamalar

- Modelde yalnızca üç öznitelik kullanılmıştır (tarafsız saha, turnuva türü, yıl); takım gücü, FIFA sıralaması veya maç içi istatistikler gibi tahmin gücünü artırabilecek değişkenler veri setinde yer almamaktadır.
- 1872–1929 arası dönem, az sayıda maç ve günümüzden farklı oyun koşulları nedeniyle gol trendi analizinde kapsam dışı bırakılmış; erken dönem futbolu hakkında yorum yapmak bu nedenle sınırlıdır.
- Beraberlik sınıfının düşük recall değeri (%7), modelin dengeli maçları ayırt etmekte güçlük çektiğini göstermektedir. Kapsamlı hiperparametre optimizasyonu yapılmamış olup bu yöntemle performans artışı mümkündür.

6. Sonuç ve Öğrenilenler

Bu çalışma, 150 yılı aşkın bir süreye yayılan uluslararası futbol verisi üzerinde uygulanan sistematik bir analizin, popüler futbol inanışlarını somut sayılarla doğrulayabildiğini göstermiştir. Ev sahibi avantajının gerçek ve ölçülebilir olduğu (kazanma oranında ~24 puanlık fark), bu avantajın büyük ölçüde tarafsız sahada kaybolduğu (~7 puanlık düşüş) ve modern futbolun 1930'lara kıyasla belirgin biçimde daha az gollü hâle geldiği (3,81'den 2,75 gol/maça) ortaya konmuştur.

Makine öğrenmesi modeli, sınırlı sayıda basit öznitelikle dahi rastgele tahminin üzerinde bir performans sağlayabilmiş, ancak beraberlik gibi daha belirsiz sonuçları yakalamakta zorlanmıştır. Bu durum, spor sonucu tahmininde takım gücüne dair doğrudan göstergelerin (FIFA puanı, son maç formu, kadro istatistikleri vb.) ne denli kritik olduğunu ortaya koymaktadır.

Proje sürecinde en kritik öğrenilen ders, hangi alt küme ile çalışıldığına dikkat edilmesinin zorunlu olduğudur: ev sahibi avantajı analizinde tarafsız maçların dışlanması sonuçları doğrudan

etkilemiştir. "Vibe coding" yöntemi verimli olmakla birlikte, üretilen her çıktının bağımsız olarak doğrulanması ve alt veri setleri arasındaki tutarlılığın (df_clean, df_normal) kontrol edilmesi şart olmuştur.

7. Kaynakça

Tüfekci, M. (2023). *International Football Results 1872–2024* [Veri seti]. Kaggle.
<https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 445, 51–56.

Pollard, R. (2008). Home advantage in football: A current review of an unsolved puzzle. *The Open Sports Sciences Journal*, 1(1), 12–14.